

# REPORTE TÉCNICO

Pipeline de Monitoreo Sísmico USGS con Apache Airflow

---

**Universidad San Francisco de Quito**

Maestría en Ciencia de Datos | Ingeniería de Datos

Taller 3

**Autores:**

- Nicolás Carrión
- Jairo Cabrera

**Fecha:** 13 de septiembre de 2026

---

# PIPELINE DE MONITOREO SÍSMICO Y ALERTA TEMPRANA USGS

## Arquitectura de Ingeniería de Datos Distribuida y Orientada a Eventos con Apache Airflow

**Tipo de Documento:** Reporte de Arquitectura e Ingeniería de Datos

**Estado del Sistema:** Producción / Operativo

**Orquestador:** Apache Airflow v2.10.2

Base de Datos Analítica: PostgreSQL v13

Entorno de Ejecución: Docker Compose / Python 3.8+

Canales de Salida: Telegram Bot API & Brevo Email API v3

---

## 1. Resumen Ejecutivo

El presente documento expone la arquitectura técnica, el diseño de componentes y las especificaciones operativas del **Pipeline de Monitoreo Sísmico y Alerta Temprana USGS**, un sistema distribuido y orientado a eventos orquestado mediante **Apache Airflow 2.10.2**.

El propósito fundamental de esta plataforma es consumir periódicamente los eventos telúricos globales reportados por la API oficial del Servicio Geológico de los Estados Unidos (USGS), transformar y normalizar las estructuras GeoJSON semiestructuradas, efectuar enriquecimiento espacial refinado (cálculo cinemático de proximidad geográfica y evaluación de umbrales críticos de magnitud), garantizar la persistencia idempotente en PostgreSQL, y despachar notificaciones multicanal automatizadas en tiempo real a través de **Telegram y Brevo (Email)**.

El sistema se fundamenta en un patrón desacoplado de **DAGs Encadenados** (*Chained DAGs*), dividiendo el flujo ETL en cinco micro-tareas orquestadas vía TriggerDagRunOperator. Esta topología asegura alta mantenibilidad, observabilidad granular por fases, aislamiento de fallos y una gestión eficiente de los recursos del sistema de archivos mediante recolección automática de residuos (*housekeeping*).

## 2. Arquitectura General del Sistema

### 2.1 Stack Tecnológico y Componentes Principales


| Componente      | Tecnología          | Versión / Especificación | Función Principal                                        |
|-----------------|---------------------|--------------------------|----------------------------------------------------------|
| Fuente de Datos | USGS Earthquake API | GeoJSON REST Service     | Ingesta continua de eventos sísmicos mundiales.          |
| Orquestador     | Apache Airflow      | 2.10.2 (LocalExecutor)   | Planificación, gestión de dependencias y observabilidad. |
| Persistencia    | PostgreSQL          | 13.0 (Relacional)        | Almacén analítico e historial unificado de sismos.       |
| Contenedores    | Docker Compose      | Engine 20.10+            | Infraestructura hiper-convergente con healthchecks.      |
| Lenguaje        | Python              | 3.8+ (Pandas, Psycopg2)  | Transformación, cálculo                                  |

| Componente     | Tecnología       | Versión / Especificación | Función Principal                           |
|----------------|------------------|--------------------------|---------------------------------------------|
|                |                  |                          | geoespacial y serialización.                |
| Notificaciones | Telegram / Brevo | Bot API / REST API v3    | Despacho push en Markdown y resúmenes HTML. |

## 2.2 Principios de Diseño Arquitectónico

1. **Desacoplamiento Estructural:** Cada fase del ciclo de vida del dato se aísla en un DAG independiente, previniendo el surgimiento de monolitos inmanejables.
2. **Trazabilidad de Ejecución:** Mantenimiento de la variable `source_run_id` a lo largo de la cadena, enlazando los artefactos intermedios y registros en base de datos con la corrida original.
3. **Idempotencia y Deduplicación:** Mecanismos de verificación primaria contra la base de datos previa a la inserción, garantizando la re-ejecución segura de cualquier tarea.
4. **Resiliencia y Reintentos:** Configuración de políticas de reintento automático y ejecución condicional para mitigar interrupciones temporales de la API o la red.
5. **Limpieza Automatizada (Zero-Disk-Leak):** Ejecución garantizada de tareas de desintegración de temporales al finalizar la secuencia de notificación.

## 2.3 Diagrama del Flujo de Datos (*Pipeline Topography*)



### 3. Detalle Técnico de los DAGs

El pipeline está segmentado en cinco DAGs especializados ubicados en el directorio `/dags`.

| DAG | Nombre de Archivo                     | Frecuencia (Schedule)                    | Salida / Artefacto                                |
|-----|---------------------------------------|------------------------------------------|---------------------------------------------------|
| 01  | <code>01_extract_data.py</code>       | <code>*/5 * * * *</code><br>(Cada 5 min) | <code>/data/raw_{run_id}.json</code>              |
| 02  | <code>02_clean_data.py</code>         | None (Trigger por DAG 01)                | <code>/data/clean_{source_run_id}.json</code>     |
| 03  | <code>03_enrich_and_ingest.py</code>  | None (Trigger por DAG 02)                | <code>/data/alerts_{source_run_id}.json</code>    |
| 04  | <code>04_format_alerts.py</code>      | None (Trigger por DAG 03)                | <code>/data/formatted_{source_run_id}.json</code> |
| 05  | <code>05_send_notifications.py</code> | None (Trigger por DAG 04)                | Notificaciones y Limpieza                         |

#### 3.1 DAG 01: Ingesta y Extracción (`01_extract_data`)

- **Propósito:** Consultar el endpoint de USGS para extraer sismos registrados dentro de un intervalo temporal definido.
- **Frecuencia de Ejecución:** `*/5 * * * *` (Cron: cada 5 minutos) con `catchup=False`.
- **Mecanismos Clave:**

- **Modo Periódico:** Consulta por defecto la ventana comprendida entre `data_interval_end - 1 día` y `data_interval_end`.
- **Soporte de Backfill / Rangos Personalizados:** Permite la inyección de parámetros dinámicos mediante la configuración del DAG Run (`conf["start_date"]` y `conf["end_date"]`).
- **Chunking Temporal:** Ante solicitudes de rangos extendidos, fragmenta automáticamente el intervalo en bloques máximos de 7 días, previniendo saturación de memoria, tiempos de espera (*timeouts*) o rechazo de payload por parte de USGS.
- **Enlace de Cadena:** Invoca al DAG 02 pasando el identificador `source_run_id`.

## 3.2 DAG 02: Limpieza y Normalización (02\_clean\_data)

- **Propósito:** Convertir la respuesta GeoJSON semiestructurada y anidada en un esquema tabular plano y estrictamente tipado.
- **Transformaciones Aplicadas:**
  - **Desestructuración de Coordenadas:** Aplanado del arreglo `geometry.coordinates` en variables individuales: `longitude`, `latitude` y `depth`.
  - **Normalización Temporal:** Conversión de marcas de tiempo en milisegundos (`properties.time`) a formato estándar ISO 8601 UTC (`YYYY-MM-DDTHH:MM:SSZ`).
  - **Filtrado de Atributos:** Selección exclusiva de campos operativamente relevantes: `id`, `magnitude`, `place`, `time`, `url`, `longitude`, `latitude`, `depth`.

## 3.3 DAG 03: Enriquecimiento Geoespacial y Persistencia (03\_enrich\_and\_ingest)

- **Propósito:** Ejecutar análisis geoespacial de proximidad, aplicar lógica de reglas de negocio para la categorización de alertas, persistir la información en PostgreSQL y filtrar eventos críticos.
- **Lógica de Negocio y Geometría Planar:**
  - **Garantía de Esquema:** Creación idempotente de la tabla `earthquake_history` si no existe previamente en PostgreSQL.

- **Deduplicación Estricta:** Consulta previa de identificadores almacenados (`SELECT id FROM earthquake_history`) para descartar registros duplicados antes del procesamiento.
- **Cálculo de Proximidad a Quito:** Cálculo de distancia plana relativa hacia el centro geográfico de Quito, Ecuador (`lat: -0.1807, lon: -78.4678`).
- **Criterios de Activación de Alerta:**
  - a. **Alta Magnitud:** `magnitude >= 6.0` (Identificador: 🌟 Magnitud Alta).
  - b. **Cercanía Geográfica:** `distancia <= 300 km` de Quito (Identificador: 🇪🇨 Cerca de Quito).
- **Persistencia:** Inserción parametrizada en PostgreSQL registrando los campos calculados (`is_high_mag, is_near_quito`).
- **Artefacto Filtrado:** Emisión exclusiva de los sismos que cumplen al menos una de las condiciones críticas en `/data/alerts_{source_run_id}.json`.

## 3.4 DAG 04: Formateo de Alertas

### (04\_format\_alerts)

- **Propósito:** Construir la capa de presentación y renderizar los mensajes adaptados a los requerimientos de cada canal de salida.
- **Formatos Generados:**
  - **Canal Telegram:** Generación de elementos estructurados en Markdown enriquecido con emojis informativos, enlaces directos al portal USGS, magnitud, profundidad e hipsometría epicentral.
  - **Canal Email (Brevo):** Construcción de una estructura HTML consolidada (`<ul><li>...</li></ul>`) con el resumen tabulado de los eventos sísmicos de alto impacto detectados en el lote actual.

## 3.5 DAG 05: Despacho y Mantenimiento

### (05\_send\_notifications)

- **Propósito:** Publicación paralela de alertas a las APIs correspondientes y ejecución de políticas de recolección de residuos.
- **Topología de Tareas:**

[ send\_telegram ] \

—→ [ cleanup\_files ]

[ send\_email ] /

- **Comportamiento:**

- **send\_telegram:** Despacha peticiones **HTTP POST** individuales a la API de Telegram Bot.
- **send\_email:** Invoca la API REST v3 de Brevo para la distribución del boletín HTML a las listas de correo especificadas.
- **cleanup\_files:** Tarea de mantenimiento final configurada con **TriggerRule.ALL\_DONE**. Elimina los archivos de staging intermedios (**raw\_\***, **clean\_\***, **alerts\_\***, **formatted\_\***) asociados al **source\_run\_id**, garantizando espacio en disco constante.

---

## 4. Modelo de Datos Relacional (PostgreSQL)

Los datos procesados se consolidan en la base de datos **sismos\_db** dentro del motor PostgreSQL 13. El esquema se compone de la tabla analítica **earthquake\_history**.

### 4.1 Definición de Esquema (DDL)

CREATE TABLE IF NOT EXISTS earthquake\_history (

|           |                                                                           |
|-----------|---------------------------------------------------------------------------|
| id        | VARCHAR PRIMARY KEY, -- Identificador único oficial USGS (ej. us7000abcd) |
| magnitude | FLOAT, -- Magnitud del sismo (Escala Mw / Mwr)                            |
| place     | VARCHAR, -- Ubicación descriptiva del epicentro                           |
| time      | VARCHAR, -- Marca de tiempo UTC en formato ISO 8601                       |
| url       | VARCHAR, -- Enlace oficial a la ficha técnica USGS                        |

```

latitude    FLOAT,          -- Latitud decimal (-90 a 90)

longitude   FLOAT,          -- Longitud decimal (-180 a 180)

depth       FLOAT,          -- Profundidad del hipocentro en kilómetros

is_high_mag BOOLEAN,        -- Flag: TRUE si magnitud >= 6.0

is_near_quito BOOLEAN       -- Flag: TRUE si distancia a Quito <= 300 km

);

```

## 4.2 Diccionario de Datos

| Campo     | Tipo      | Nulidad    | Descripción Técnica                                             |
|-----------|-----------|------------|-----------------------------------------------------------------|
| id        | VARCHAR ▾ | NOT NULL ▾ | Clave primaria.<br>Código alfanumérico único asignado por USGS. |
| magnitude | FLOAT ▾   | NULL ▾     | Magnitud calculada en escala de momento u homóloga.             |
| place     | VARCHAR ▾ | NULL ▾     | Cadena descriptiva de la región sísmica reportada.              |
| time      | VARCHAR ▾ | NULL ▾     | Timestamp formateado en norma UTC ISO 8601.                     |

| Campo         | Tipo      | Nulidad    | Descripción Técnica                                         |
|---------------|-----------|------------|-------------------------------------------------------------|
| url           | VARCHAR ▾ | NULL ▾     | URL canónica para auditoría directa en el portal USGS.      |
| latitude      | FLOAT ▾   | NULL ▾     | Coordenada esférica y espacial de latitud.                  |
| longitude     | FLOAT ▾   | NULL ▾     | Coordenada esférica y espacial de longitud.                 |
| depth         | FLOAT ▾   | NULL ▾     | Profundidad del foco sísmico (hipocentro) expresada en km.  |
| is_high_mag   | BOOLEAN ▾ | NOT NULL ▾ | Marcador lógico de evento sísmico mayor de escala.          |
| is_near_quito | BOOLEAN ▾ | NOT NULL ▾ | Marcador de proximidad geográfica a la capital ecuatoriana. |

---

# 5. Despliegue, Configuración y Operación

## 5.1 Requisitos Previos de Infraestructura

- **Motor de Contenedores:** Docker Desktop v20.10+ o Docker Engine con Docker Compose v2+.
- **Credenciales Bot Telegram:** API Token obtenido mediante [@BotFather](#) en Telegram.
- **Credenciales Brevo:** Clave de API v3 activa y dirección de remitente verificada.

## 5.2 Estructura de Variables de Entorno (.env)

# --- Configuración Base de Airflow ---

AIRFLOW\_UID=50000

AIRFLOW\_PROJ\_DIR=.

\_PIP\_ADDITIONAL\_REQUIREMENTS=pandas requests psycopg2-binary

\_AIRFLOW\_WWW\_USER\_USERNAME=airflow

\_AIRFLOW\_WWW\_USER\_PASSWORD=airflow

# --- Credenciales y Tokens de Servicios de Alerta ---

TELEGRAM\_BOT\_TOKEN=123456789:ABCdefGHIjkIMNOpqrSTUVwxyZ

TELEGRAM\_CHAT\_ID=-100123456789

BREVO\_API\_KEY=xkeysib-xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx

BREVO\_SENDER\_EMAIL=alertas@dominio-seguro.com

ALERT\_EMAIL=analista.riesgos@empresa.com, guardia.monitoreo@empresa.com

## 5.3 Procedimiento de Puesta en Marcha

### 1. Clonación e Inicialización de Archivos:

```
git clone <url-del-repositorio>
```

```
cd airflow_sismos
```

```
cp .env.example .env
```

### 2. Levantamiento del Ecosistema Docker:

```
docker-compose up -d --build
```

El servicio `airflow-init` creará automáticamente la base de datos de metadatos de Airflow, aplicará migraciones, creará el usuario administrador `airflow` y asignará permisos de lectura/escritura en el volumen `/opt/airflow/data`.

### 3. Verificación de Puertos Operativos:

- **Interfaz Web Airflow:** `http://localhost:8080` (Usuario: `airflow` | Clave: `airflow`)
- **Base de Datos PostgreSQL:** `localhost:5432` (DB: `sismos_db` | Usuario: `airflow`)

## 5.4 Ejecución de Cargas Históricas (*Backfilling*)

Para realizar ingesta retroactiva o procesar ventanas arbitrarias del pasado, se debe activar el **DAG 01** vía interfaz gráfica o CLI de Airflow, suministrando la configuración JSON:n

```
{  
  "start_date": "2024-01-01T00:00:00Z",  
  "end_date": "2024-01-15T00:00:00Z"  
}
```

---

# 6. Justificación Geotectónica del Criterio de Alerta (Quito, Ecuador)

La inclusión de un radio de alerta de \*\*300 km en torno a Quito\*\* (`lat: -0.1807`, `lon: -78.4678`) responde a la elevada vulnerabilidad y complejidad geodinámica del Distrito Metropolitano de Quito (DMQ).

|         |                                                                         |
|---------|-------------------------------------------------------------------------|
| +-----+ |                                                                         |
|         | SISTEMA DE FALLAS INVERSAS DE QUITO                                     |
|         |                                                                         |
|         | Proyección: ~60 km de longitud (San Antonio de Pichincha - Tambillo)    |
|         | Buzamiento: 55° hacia el Occidente                                      |
|         | Aceleración Máxima del Terreno (PGA): ~0.4g (Período retorno 475 años)  |
|         | Magnitudes Potenciales: M5.9 - M6.4 (Individual) / M7.1 (Ruptura Total) |
| +-----+ |                                                                         |

El territorio está expuesto a terremotos corticales intra-placa originados en el \*\*Sistema de Fallas Inversas de Quito (SFIQ)\*\*\*, una estructura tectónica activa de aproximadamente 60 km de longitud que atraviesa la ciudad de Norte a Sur. Investigaciones geofísicas determinan que este sistema posee capacidad para generar eventos de magnitud individual entre \$5.9\$ y \$6.4\$, o sismos combinados de hasta \$7.1\$ Mw en escenarios de ruptura total.

Adicionalmente, debido a la amplificación por efectos de sitio en suelos volcánicos y depósitos aluviales, un evento sísmico de gran magnitud dentro de los 300 km de radio representa una amenaza crítica que justifica la emisión inmediata de alertas de tiempo real.

---

# 7. Hoja de Ruta Tecnológica y Mejoras Futuras

Para evolucionar esta plataforma hacia un estándar de alta disponibilidad de grado industrial, se establecen seis ejes estratégicos de expansión técnica:

|  |                |  |                      |  |           |  |                   |  |
|--|----------------|--|----------------------|--|-----------|--|-------------------|--|
|  | Área de Mejora |  | Tecnología Propuesta |  | Prioridad |  | Impacto Operativo |  |
|  | :---           |  | :---                 |  | :---      |  | :---              |  |

| **Streaming en Tiempo Real** | Apache Kafka / Flink | Alta | Reducción de latencia de 5 min a sub-segundo via WebSockets/SSE. |

| **Análisis Espacial Avanzado** | PostGIS & Haversine | Alta | Precisión geodésica elipsoidal (`ST_DistanceSphere`) e índices `GIST`. |

| **Business Intelligence** | Apache Superset / Metabase | Media | Dashboards interactivos, mapas de calor y series temporales. |

| **Modelado de Machine Learning** | DBSCAN / PyTorch PGA | Media | Detección no supervisada de enjambres sísmicos y estimación de daño. |

| **Observabilidad & Linaje** | OpenLineage / Soda Core | Media | Control de calidad automático de datos y trazabilidad de extremo a extremo. |

| **Despliegue Cloud Nativo** | Kubernetes / Terraform | Baja | Escala horizontal elástica mediante `KubernetesExecutor`. |

## ## 7.1 Ingesta Continua con Streaming de Baja Latencia

Sustituir la consulta por lotes (*\*polling\** cada 5 minutos) por una arquitectura basada en **Apache Kafka** o **Redpanda**, conectada directamente al stream de eventos WebSocket/SSE del USGS. La incorporación de un motor de procesamiento como **Apache Flink** permitirá calcular ventanas deslizantes para la detección automatizada de réplicas (*\*aftershocks\**).

## ## 7.2 Migración a PostGIS y Geodesia Elipsoidal

Habilitar la extensión espacial `postgis` sobre la base de datos PostgreSQL. Esto sustituirá la fórmula de distancia plana euclidiana por el algoritmo de Vincenty o la función geodésica `ST_DistanceSphere` sobre tipos de datos nativos `GEOMETRY(Point, 4326)`, permitiendo cruces espaciales inmediatos con capas vectoriales de fallas tectónicas y densidad poblacional.

## ## 7.3 Capa Analítica y Visualización Interactiva


Integrar **Apache Superset** para exponer métricas clave a los equipos de gestión de riesgos:

\* \*\*Mapas de Densidad Hipocentral\*\*:

Representación tridimensional del foco sísmico según profundidad.


Este diagrama ilustra un mapa de densidad hipocentral tridimensional. Muestra un eje vertical que representa la profundidad y un eje horizontal que representa la distancia o magnitud. Se visualiza una distribución de puntos o una superficie que indica la densidad de los focos sísmicos en función de estas variables.

\* \*\*Histogramas de Frecuencia\*\*:

Distribución acumulada por rangos de magnitud y distancia urbana.

Este diagrama muestra un histograma de frecuencia. El eje horizontal representa rangos de magnitud y distancia urbana, mientras que el eje vertical representa la frecuencia o densidad acumulada. Las barras del histograma muestran la distribución de los eventos sísmicos en estos rangos.

\* \*\*Alertas por Fallas Específicas\*\*:

Clasificación de eventos según su proximidad a sistemas de fallas activas localizadas.

Este diagrama clasifica los eventos sísmicos basándose en su proximidad a sistemas de fallas activas localizadas. Se muestran líneas que representan las fallas y puntos que indican la ubicación y clasificación de los eventos en relación con estas fallas.