

REPORTE TÉCNICO

Pipeline de Monitoreo Sísmico USGS con Apache Airflow

Universidad San Francisco de Quito

Maestría en Ciencia de Datos | Ingeniería de Datos

Taller 3

Autores:

- Nicolás Carrión
- Jairo Cabrera

Fecha: 13 de septiembre de 2026

PIPELINE DE MONITOREO SÍSMICO Y ALERTA TEMPRANA USGS

Arquitectura de Ingeniería de Datos Distribuida y Orientada a Eventos con Apache Airflow

Tipo de Documento: Reporte de Arquitectura e Ingeniería de Datos

Estado del Sistema: Producción / Operativo

Orquestador: Apache Airflow v2.10.2

Base de Datos Analítica: PostgreSQL v13

Entorno de Ejecución: Docker Compose / Python 3.8+

Canales de Salida: Telegram Bot API & Brevo Email API v3

1. Resumen Ejecutivo

El presente documento expone la arquitectura técnica, el diseño de componentes y las especificaciones operativas del **Pipeline de Monitoreo Sísmico y Alerta Temprana USGS**, un sistema distribuido y orientado a eventos orquestado mediante **Apache Airflow 2.10.2**.

El propósito fundamental de esta plataforma es consumir periódicamente los eventos telúricos globales reportados por la API oficial del Servicio Geológico de los Estados Unidos (USGS), transformar y normalizar las estructuras GeoJSON semiestructuradas, efectuar enriquecimiento espacial refinado (cálculo cinemático de proximidad geográfica y evaluación de umbrales críticos de magnitud), garantizar la persistencia idempotente en PostgreSQL, y despachar notificaciones multicanal automatizadas en tiempo real a través de **Telegram y Brevo (Email)**.

El sistema se fundamenta en un patrón desacoplado de **DAGs Encadenados** (*Chained DAGs*), dividiendo el flujo ETL en cinco micro-tareas orquestadas vía TriggerDagRunOperator. Esta topología asegura alta mantenibilidad, observabilidad granular por fases, aislamiento de fallos y una gestión eficiente de los recursos del sistema de archivos mediante recolección automática de residuos (*housekeeping*).

2. Arquitectura General del Sistema

2.1 Stack Tecnológico y Componentes Principales


Componente	Tecnología	Versión / Especificación	Función Principal
Fuente de Datos	USGS Earthquake API	GeoJSON REST Service	Ingesta continua de eventos sísmicos mundiales.
Orquestador	Apache Airflow	2.10.2 (LocalExecutor)	Planificación, gestión de dependencias y observabilidad.
Persistencia	PostgreSQL	13.0 (Relacional)	Almacén analítico e historial unificado de sismos.
Contenedores	Docker Compose	Engine 20.10+	Infraestructura hiper-convergente con healthchecks.
Lenguaje	Python	3.8+ (Pandas, Psycopg2)	Transformación, cálculo

Componente	Tecnología	Versión / Especificación	Función Principal
			geoespacial y serialización.
Notificaciones	Telegram / Brevo	Bot API / REST API v3	Despacho push en Markdown y resúmenes HTML.

2.2 Principios de Diseño Arquitectónico

- 1. **Desacoplamiento Estructural:** Cada fase del ciclo de vida del dato se aísla en un DAG independiente, previniendo el surgimiento de monolitos inmanejables.
- 2. **Trazabilidad de Ejecución:** Mantenimiento de la variable `source_run_id` a lo largo de la cadena, enlazando los artefactos intermedios y registros en base de datos con la corrida original.
- 3. **Idempotencia y Deduplicación:** Mecanismos de verificación primaria contra la base de datos previa a la inserción, garantizando la re-ejecución segura de cualquier tarea.
- 4. **Resiliencia y Reintentos:** Configuración de políticas de reintento automático y ejecución condicional para mitigar interrupciones temporales de la API o la red.
- 5. **Limpieza Automatizada (Zero-Disk-Leak):** Ejecución garantizada de tareas de desintegración de temporales al finalizar la secuencia de notificación.

2.3 Diagrama del Flujo de Datos (Pipeline Topography)



3. Detalle Técnico de los DAGs

El pipeline está segmentado en cinco DAGs especializados ubicados en el directorio `/dags`.

DAG	Nombre de Archivo	Frecuencia (Schedule)	Salida / Artefacto
01	<code>01_extract_data.py</code>	<code>*/5 * * * *</code> (Cada 5 min)	<code>/data/raw_{run_id}.json</code>
02	<code>02_clean_data.py</code>	None (Trigger por DAG 01)	<code>/data/clean_{source_run_id}.json</code>
03	<code>03_enrich_and_ingest.py</code>	None (Trigger por DAG 02)	<code>/data/alerts_{source_run_id}.json</code>
04	<code>04_format_alerts.py</code>	None (Trigger por DAG 03)	<code>/data/formatted_{source_run_id}.json</code>
05	<code>05_send_notifications.py</code>	None (Trigger por DAG 04)	Notificaciones y Limpieza

3.1 DAG 01: Ingesta y Extracción (`01_extract_data`)

- **Propósito:** Consultar el endpoint de USGS para extraer sismos registrados dentro de un intervalo temporal definido.
- **Frecuencia de Ejecución:** `*/5 * * * *` (Cron: cada 5 minutos) con `catchup=False`.
- **Mecanismos Clave:**

- **Modo Periódico:** Consulta por defecto la ventana comprendida entre `data_interval_end - 1 día` y `data_interval_end`.
- **Soporte de Backfill / Rangos Personalizados:** Permite la inyección de parámetros dinámicos mediante la configuración del DAG Run (`conf["start_date"]` y `conf["end_date"]`).
- **Chunking Temporal:** Ante solicitudes de rangos extendidos, fragmenta automáticamente el intervalo en bloques máximos de 7 días, previniendo saturación de memoria, tiempos de espera (*timeouts*) o rechazo de payload por parte de USGS.
- **Enlace de Cadena:** Invoca al DAG 02 pasando el identificador `source_run_id`.

3.2 DAG 02: Limpieza y Normalización (02_clean_data)

- **Propósito:** Convertir la respuesta GeoJSON semiestructurada y anidada en un esquema tabular plano y estrictamente tipado.
- **Transformaciones Aplicadas:**
 - **Desestructuración de Coordenadas:** Aplanado del arreglo `geometry.coordinates` en variables individuales: `longitude`, `latitude` y `depth`.
 - **Normalización Temporal:** Conversión de marcas de tiempo en milisegundos (`properties.time`) a formato estándar ISO 8601 UTC (`YYYY-MM-DDTHH:MM:SSZ`).
 - **Filtrado de Atributos:** Selección exclusiva de campos operativamente relevantes: `id`, `magnitude`, `place`, `time`, `url`, `longitude`, `latitude`, `depth`.

3.3 DAG 03: Enriquecimiento Geoespacial y Persistencia (03_enrich_and_ingest)

- **Propósito:** Ejecutar análisis geoespacial de proximidad, aplicar lógica de reglas de negocio para la categorización de alertas, persistir la información en PostgreSQL y filtrar eventos críticos.
- **Lógica de Negocio y Geometría Planar:**
 - **Garantía de Esquema:** Creación idempotente de la tabla `earthquake_history` si no existe previamente en PostgreSQL.

- **Deduplicación Estricta:** Consulta previa de identificadores almacenados (`SELECT id FROM earthquake_history`) para descartar registros duplicados antes del procesamiento.
- **Cálculo de Proximidad a Quito:** Cálculo de distancia plana relativa hacia el centro geográfico de Quito, Ecuador (`lat: -0.1807, lon: -78.4678`).
- **Criterios de Activación de Alerta:**
 - a. **Alta Magnitud:** `magnitude >= 6.0` (Identificador: 🌟 Magnitud Alta).
 - b. **Cercanía Geográfica:** `distancia <= 300 km` de Quito (Identificador: 🇪🇨 Cerca de Quito).
- **Persistencia:** Inserción parametrizada en PostgreSQL registrando los campos calculados (`is_high_mag, is_near_quito`).
- **Artefacto Filtrado:** Emisión exclusiva de los sismos que cumplen al menos una de las condiciones críticas en `/data/alerts_{source_run_id}.json`.

3.4 DAG 04: Formateo de Alertas

(04_format_alerts)

- **Propósito:** Construir la capa de presentación y renderizar los mensajes adaptados a los requerimientos de cada canal de salida.
- **Formatos Generados:**
 - **Canal Telegram:** Generación de elementos estructurados en Markdown enriquecido con emojis informativos, enlaces directos al portal USGS, magnitud, profundidad e hipsometría epicentral.
 - **Canal Email (Brevo):** Construcción de una estructura HTML consolidada (`<ul><li>...</li></ul>`) con el resumen tabulado de los eventos sísmicos de alto impacto detectados en el lote actual.

3.5 DAG 05: Despacho y Mantenimiento

(05_send_notifications)

- **Propósito:** Publicación paralela de alertas a las APIs correspondientes y ejecución de políticas de recolección de residuos.
- **Topología de Tareas:**

[send_telegram] \

—→ [cleanup_files]

[send_email] /

- **Comportamiento:**

- **send_telegram:** Despacha peticiones **HTTP POST** individuales a la API de Telegram Bot.
- **send_email:** Invoca la API REST v3 de Brevo para la distribución del boletín HTML a las listas de correo especificadas.
- **cleanup_files:** Tarea de mantenimiento final configurada con **TriggerRule.ALL_DONE**. Elimina los archivos de staging intermedios (**raw_***, **clean_***, **alerts_***, **formatted_***) asociados al **source_run_id**, garantizando espacio en disco constante.

4. Modelo de Datos Relacional (PostgreSQL)

Los datos procesados se consolidan en la base de datos **sismos_db** dentro del motor PostgreSQL 13. El esquema se compone de la tabla analítica **earthquake_history**.

4.1 Definición de Esquema (DDL)

CREATE TABLE IF NOT EXISTS earthquake_history (

id VARCHAR PRIMARY KEY, -- Identificador único oficial USGS (ej. us7000abcd)

magnitude FLOAT, -- Magnitud del sismo (Escala Mw / Mwr)

place VARCHAR, -- Ubicación descriptiva del epicentro

time VARCHAR, -- Marca de tiempo UTC en formato ISO 8601

url VARCHAR, -- Enlace oficial a la ficha técnica USGS


```

latitude    FLOAT,          -- Latitud decimal (-90 a 90)

longitude   FLOAT,          -- Longitud decimal (-180 a 180)

depth       FLOAT,          -- Profundidad del hipocentro en kilómetros

is_high_mag BOOLEAN,        -- Flag: TRUE si magnitud >= 6.0

is_near_quito BOOLEAN       -- Flag: TRUE si distancia a Quito <= 300 km

);

```

4.2 Diccionario de Datos

Campo	Tipo	Nulidad	Descripción Técnica
id	VARCHAR ▾	NOT NULL ▾	Clave primaria. Código alfanumérico único asignado por USGS.
magnitude	FLOAT ▾	NULL ▾	Magnitud calculada en escala de momento u homóloga.
place	VARCHAR ▾	NULL ▾	Cadena descriptiva de la región sísmica reportada.
time	VARCHAR ▾	NULL ▾	Timestamp formateado en norma UTC ISO 8601.

Campo	Tipo	Nulidad	Descripción Técnica
url	VARCHAR ▾	NULL ▾	URL canónica para auditoría directa en el portal USGS.
latitude	FLOAT ▾	NULL ▾	Coordenada esférica y espacial de latitud.
longitude	FLOAT ▾	NULL ▾	Coordenada esférica y espacial de longitud.
depth	FLOAT ▾	NULL ▾	Profundidad del foco sísmico (hipocentro) expresada en km.
is_high_mag	BOOLEAN ▾	NOT NULL ▾	Marcador lógico de evento sísmico mayor de escala.
is_near_quito	BOOLEAN ▾	NOT NULL ▾	Marcador de proximidad geográfica a la capital ecuatoriana.

5. Despliegue, Configuración y Operación

5.1 Requisitos Previos de Infraestructura

- **Motor de Contenedores:** Docker Desktop v20.10+ o Docker Engine con Docker Compose v2+.
- **Credenciales Bot Telegram:** API Token obtenido mediante @BotFather en Telegram.
- **Credenciales Brevo:** Clave de API v3 activa y dirección de remitente verificada.

5.2 Estructura de Variables de Entorno (.env)

--- Configuración Base de Airflow ---

AIRFLOW_UID=50000

AIRFLOW_PROJ_DIR=.

_PIP_ADDITIONAL_REQUIREMENTS=pandas requests psycpg2-binary

_AIRFLOW_WWW_USER_USERNAME=airflow

_AIRFLOW_WWW_USER_PASSWORD=airflow

--- Credenciales y Tokens de Servicios de Alerta ---

TELEGRAM_BOT_TOKEN=123456789:ABCdefGHIjkIMNOpqrSTUVwxyZ

TELEGRAM_CHAT_ID=-100123456789

BREVO_API_KEY=xkeysib-xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx

BREVO_SENDER_EMAIL=alertas@dominio-seguro.com

ALERT_EMAIL=analista.riesgos@empresa.com, guardia.monitoreo@empresa.com

5.3 Procedimiento de Puesta en Marcha

1. Clonación e Inicialización de Archivos:

```
git clone <url-del-repositorio>
```

```
cd airflow_sismos
```

```
cp .env.example .env
```

2. Levantamiento del Ecosistema Docker:

```
docker-compose up -d --build
```

El servicio `airflow-init` creará automáticamente la base de datos de metadatos de Airflow, aplicará migraciones, creará el usuario administrador `airflow` y asignará permisos de lectura/escritura en el volumen `/opt/airflow/data`.

3. Verificación de Puertos Operativos:

- **Interfaz Web Airflow:** `http://localhost:8080` (Usuario: `airflow` | Clave: `airflow`)
- **Base de Datos PostgreSQL:** `localhost:5432` (DB: `sismos_db` | Usuario: `airflow`)

5.4 Ejecución de Cargas Históricas (*Backfilling*)

Para realizar ingesta retroactiva o procesar ventanas arbitrarias del pasado, se debe activar el **DAG 01** vía interfaz gráfica o CLI de Airflow, suministrando la configuración JSON:n

```
{  
  "start_date": "2024-01-01T00:00:00Z",  
  "end_date": "2024-01-15T00:00:00Z"  
}
```

6. Justificación Geotectónica del Criterio de Alerta (Quito, Ecuador)

La inclusión de un radio de alerta de 300 km en torno a Quito (`lat: -0.1807`, `lon: -78.4678`) responde a la elevada vulnerabilidad y complejidad geodinámica del Distrito Metropolitano de Quito (DMQ).

+-----+	
SISTEMA DE FALLAS INVERSAS DE QUITO	
Proyección: ~60 km de longitud (San Antonio de Pichincha - Tambillo)	
Buzamiento: 55° hacia el Occidente	
Aceleración Máxima del Terreno (PGA): ~0.4g (Período retorno 475 años)	
Magnitudes Potenciales: M5.9 - M6.4 (Individual) / M7.1 (Ruptura Total)	
+-----+	

El territorio está expuesto a terremotos corticales intra-placa originados en el Sistema de Fallas Inversas de Quito (SFIQ), una estructura tectónica activa de aproximadamente 60 km de longitud que atraviesa la ciudad de Norte a Sur. Investigaciones geofísicas determinan que este sistema posee capacidad para generar eventos de magnitud individual entre \$5.9\$ y \$6.4\$, o sismos combinados de hasta \$7.1\$ Mw en escenarios de ruptura total.

Adicionalmente, debido a la amplificación por efectos de sitio en suelos volcánicos y depósitos aluviales, un evento sísmico de gran magnitud dentro de los 300 km de radio representa una amenaza crítica que justifica la emisión inmediata de alertas de tiempo real.

7. Hoja de Ruta Tecnológica y Mejoras Futuras

Para evolucionar esta plataforma hacia un estándar de alta disponibilidad de grado industrial, se establecen seis ejes estratégicos de expansión técnica:

Área de Mejora	Tecnología Propuesta	Prioridad	Impacto Operativo
Streaming en Tiempo Real	Apache Kafka / Flink	Alta	Reducción de latencia de 5 min a sub-segundo via WebSockets/SSE.
Análisis Espacial Avanzado	PostGIS & Haversine	Alta	Precisión geodésica elipsoidal (ST_DistanceSphere) e índices GIST .
Business Intelligence	Apache Superset / Metabase	Media	Dashboards interactivos, mapas de calor y series temporales.
Modelado de Machine Learning	DBSCAN / PyTorch PGA	Media	Detección no supervisada de enjambres sísmicos y estimación de daño.
Observabilidad & Linaje	OpenLineage / Soda Core	Media	Control de calidad automático de datos y trazabilidad de extremo a extremo.
Despliegue Cloud Nativo	Kubernetes / Terraform	Baja	Escala horizontal elástica mediante KubernetesExecutor .

7.1 Ingesta Continua con Streaming de Baja Latencia

Sustituir la consulta por lotes (polling cada 5 minutos) por una arquitectura basada en Apache Kafka o Redpanda, conectada directamente al stream de eventos WebSocket/SSE del USGS. La incorporación de un motor de procesamiento como Apache Flink permitirá calcular ventanas deslizantes para la detección automatizada de réplicas.

7.2 Migración a PostGIS y Geodesia Elipsoidal

Habilitar la extensión espacial `postgis` sobre la base de datos PostgreSQL. Esto sustituirá la fórmula de distancia plana euclidiana por el algoritmo de Vincenty o la función geodésica `ST\_DistanceSphere` sobre tipos de datos nativos `GEOMETRY(Point, 4326)`, permitiendo cruces espaciales inmediatos con capas vectoriales de fallas tectónicas y densidad poblacional.

7.3 Capa Analítica y Visualización Interactiva

Integrar Apache Superset para exponer métricas clave a los equipos de gestión de riesgos:

- * **Mapas de Densidad Hipocentral:** Representación tridimensional del foco sísmico según profundidad.
- * **Histogramas de Frecuencia:** Distribución acumulada por rangos de magnitud y distancia urbana.
- * **Alertas por Fallas Específicas:** Clasificación de eventos según su proximidad a sistemas de fallas activas localizadas.